

E-Nudge

AZURE AI 기반 유해 댓글 넋지 시스템

Contents

01
WHY
문제 인식
시장과 기회

02
WHAT
서비스 컨셉
시스템 설계

03
HOW
모델 개발
구현과 시연

04
BEYOND
책임 있는 AI

01 . 문제인식

프로젝트 선정 배경

지금 이 순간의 사이버 불링, 숫자가 말한다



한국 청소년 5명 중 1명

20.1%


사이버불링 경험 (Korea Times, 2024)



사이버 언어폭력

38.1%

가장 높은 사이버불링 유형 (교육부, 2024)



악플이 연예인 자살에 영향

97.7%

국민 10명 중 9명 이상 동의 (한국언론진흥재단, 2019)

유해성의 비즈니스 임팩트

유해성은 비용이다

설리 구하라 사망 (2019)

카카오 연예뉴스 댓글 전면 폐지

에스파 윈터 살해 협박 (2023)

SM 법적 대응 + 경호 투입

Unilever 광고 철수 (2020)

글로벌 Top3 광고주, Facebook \$2.5억 광고비 중단

주요 스트리머의 독성 채팅 문제 제기(2025)

팬 과몰입(괴롭힘→물리적 위협)으로 방송 중단

트래픽 자체를 포기

아티스트 안전 비용 폭증

대형 광고주의 플랫폼 이탈

engagement 수익 구조 위협

02 . 시장과 기회

떠드는 곳에 돈이 돈다

Nudge: 선택지를 없애지 않으면서 행동을 바꾸는 설계 (Thaler & Sunstein, 2008) — engagement를 죽이지 않는 방법

팬덤 커뮤니티

1,200만



MAU / 2025 흑자 전환

스트리밍 플랫폼


39%



MAU / 2025 흑자 전환

주요 플랫폼
라이브커머스

₩3.5조



MAU / 2025 흑자 전환

콘텐츠 모더레이션



\$227억



MAU / 2025 흑자 전환

Sources: Music Business Worldwide, Streams Charts, Grand View Research (2024), 씨브이쓰리 (2024)

시장 규모와 포지셔닝



프로젝트 타겟

	1차 타겟 (PoC)	확장 타겟	시장 신호
B2B			
커뮤니티	디시, 더쿠, 팬카페, 소규모 Discord	신규 팬덤 플랫폼, 버티컬 SNS	자체 인프라 없음 → API 즉시 도입
커머스	스마트스토어 라이브, 인플루언서 마켓	중소 쇼핑몰 라이브, 리뷰 시스템	실시간 독성 = 구매전환 직격
기업	스타트업 Slack, Discord 팀서버	기업 내부 채팅, 익명 게시판	직장 내 괴롭힘 방지법
B2G			
공공	정부 민원 게시판, 공공 포털 댓글	지자체 AI 도입 사업, 교육 플랫폼	AI 기본법(2026) → 안전 체계 구축 의무화

PoC 1차 → 인프라 없는 버티컬

도입 결정 빠름 / API 연동 단순 / 즉시 효과 측정

검증 후 확장 → 신규 플랫폼 + 공공

플랫폼 신규 론칭 시 Day 1 도입 / AI 기본법 규제 대응

03 . 서비스 컨셉

WHY

차단은 시장을, 방치는 유저를 죽인다

인게이지먼트의 역설, 방치도 차단도 답이 아니다

방치하면

독성 노출 시 비속어 게시 **2~3배 ↑**

유저 이탈 → 광고주 이탈 → 수익 하락

커뮤니티 전체 독성 전이 가속

차단하면

독성 숨기면 engagement 동반 하락

표현의 자유 위축 → 음지화 가속

커뮤니티 활성화도 전반 감소

HOW

공격성에 기회, 혐오에는 차단을 설계

Nudge: 선택지를 없애지 않으면서 행동을 바꾸는 설계 (Thaler & Sunstein, 2008) — engagement를 죽이지 않는 방법



PROOF

네티지는 정말 효과가 있는가?

Twitter 공격성 트윗

6%

2021 RCT 실험
게시 전 네티지 →
공격적 트윗 6% 감소

Nextdoor 자율 정화

26%

AI 재작성 제안 →
유저 26% 수용
위반 콘텐츠 15% 감소

Riot Games 경고 시스템

92%

인게임 경고 후
92% 유저가 재범하지 않음

자율적 행동 변화 및 위반율 감소 효과, 글로벌 플랫폼이 증명한 네티지의 효용성

Sources: Twitter(2021), Nextdoor(2023), Riot Games

팀 구성 및 역할



조운재

팀 리드 · 전체 파이프라인 설계 및 검증



오준상

이미지 데이터 수집 · 모델링 · 윤리 검증



황주희

오퍼레이션 · 기술문서 작성 · 전처리



박용주

백엔드 · DB · FastAPI



성유리

프론트엔드 · UX · UI




임경아


시장성 검증 · ML 파이프라인 구축

04 . 시스템 설계

System Architecture




System Architecture



Text Data Collection & Selection

항목	AI Hub	BEEP! 	K-MHaS
데이터 성격	인공 생성	실제 연예인 뉴스 댓글	실제 뉴스 댓글
적합성	낮음	매우 높음	높음

Data Pre-processing



(TF-IDF Vectorizer)

Data Pre-processing


"진짜 이 사람은 너무 무례하네요!!" —————> 진짜/MAG + 사람/NNG + 너무/MAG + 무례하/VA + !!/SW

단어	특징	점수 (Weight)
진짜, 너무	모든 문장에 흔함	Low (↓)
무례, 이기적	특정 문장에만 등장	High (↑)


Image Data Collection

Direct Collection		
데이터 성격	유해한 이모지 (폭력, 범죄, 비하, 모욕성 등)	한국 온라인 커뮤니티 상의 맥락적 조롱이 섞인 유해 이미지 데이터


System Architecture




System Architecture




System Architecture




System Architecture




Store in DB



Store in DB



Store in DB



05 . 모델 개발

Model Training Pipeline



BEEP! 데이터셋

클래스 분포

none 44.1% | offensive 31.6% | hate 24.2%

IAA = 0.496

(Inter-Annotator Agreement, 작업자 간 일치도)

Moon et al., SocialNLP@ACL 2020

Model Selection

선형

- Logistic Regression (LR)
- Linear Support Vector Classifier (Linear SVC)
- One-vs-One (OvO) (LR)

빠르고 해석이 쉬움

트리

- Random Forest (RF)
- Gradient Boosting Classifier (GBC)

비선형
패턴 포착에 강함

확률

- Multinomial Naïve Bayes (MNB)
- Complement Naïve Bayes (CNB)


텍스트 분류에 특화

신경망/앙상블

- Multilayer Perceptron (MLP)
- Voting (LR+NB+SVC)

복잡한
패턴 학습 및 모델 결합

Model Training



51 ~ 52%로 수렴

GridSearchCV

모델 계열	모델	f1_macro	변화
선형	LR	0.5177	▲ 미미
선형	Linear SVC	0.5168	▲ 미미
트리	RF	0.5066	▲ 미미
앙상블	GBC	0.4764	▼ 하락

데이터를 늘리면?

Pseudo Labeling

검증된 반지도학습 기법으로 203만 건 비라벨 데이터 활용

Pseudo Labeling

학습된 모델의 예측값을 라벨로 사용해 비라벨 데이터를 학습에 활용하는 반지도학습 기법. Google·Meta 등 대규모 학습의 표준 방법론 (Lee, 2013 · 4,300+ citations)
Stanford AI Report 수업에서 등장한 "LLM as Judge" 개념 : 모델이 사람 대신 판정하는 트렌드로, 규모를 작게 해 ML 라벨러에 적용할 수 있는 구조


클래스별 전문 라벨러 배정

클래스	라벨러 모델	정밀도	배정 방식
hate	MNB (0.71) + GBC (0.60)	합의 ≥ 0.6	2개 모델 합의
offensive	GBC (0.43)	단독 ≥ (최고 prec)	차순위 모델 스코어 0.3 대로 합의 불가
none	LR (0.64) + OvO (0.63)	합의 ≥ 0.6	2개 모델 합의

Pseudo Labeling

검증된 반지도학습 기법으로 203만 건 비라벨 데이터 활용

실험 흐름



Pseudo Labeling & KcELECTRA

변수 통제: 같은 모델, 데이터만 다르게

KcELECTRA (원본 7,896건)

accuracy

0.706

hate F1

0.706

사람이 라벨링한 원본 데이터만으로

KcELECTRA + pseudo (1:1)

accuracy

0.706

hate F1

0.706

Pseudo 6,316건만 1:1 혼합해도 전 클래스 하락

ML 점수가 낮아 pseudo 효과처럼 보였지만 DL 기준으로 측정하니 실제론 노이즈
데이터의 양이 아닌 질 → 피드백 루프 설계의 출발점

최종 선정 모델: ML (TF-IDF + CNB)

기준	ML (TF-IDF + CNB)	DL (KcELECTRA)
성능 (hate F1)	MNB (0.71) + GBC (0.60)	0.739
배포	.pkl, CPU 서빙	GPU 필요, 서버 인프라

Phase 1 (MVP)

ML 선택 → 빠른 배포 + 판정 근거 설명 가능

Phase 2 (피드백 루프 후)

사용자 라벨 축적 → KcELECTRA fine-tuning 전환

Azure Custom Vision

27,758

이미지

K-Hate Vision 데이터셋 구축

2-Layer

구조

Base: NSFW 5cls
K-Hate: 64로고 + 627밈


**Azure Custom
Vision**

MS 클라우드 기반
이미지 분류 API

Azure Custom Vision

Iteration 5

Finished training on 2026. 3. 3. 오후 5:13:12 using General [A2] domain
Iteration id: 88f3f914-1fea-448d-8151-68aeae206a60
Classification type: Multiclass (Single tag per image)
Published as: Iteration5




Performance Per Tag

Tag	Precision ^	Recall	A.P.	Image count ⚠
hate memes	96.9%	95.4%	98.9%	649
porn	96.3%	95.1%	98.9%	5559
neutral	93.7%	90.6%	96.3%	5586
sexy	92.1%	95.8%	98.0%	5543
hentai	91.7%	92.8%	97.6%	5571
neutral drawings	88.6%	86.6%	94.3%	4808
hate logo	81.8%	100.0%	98.9%	42

Troubleshooting

52%에서 시작해 데이터셋에 도착하기까지




모델 → 데이터 → 라벨의 품질

06 . 구현과 시연

E-Nudge

Azure AI 기반 공감 네티지형 콘텐츠 모더레이션
통합 관제 솔루션



서비스 시연 : E_Nudge 실시간 개입



“AI 경고 (Warning) 알림”

사용자 텍스트 및 이미지에 대한 AI의
실시간 팝업 알림 및 수정 제안



“AI 위험 (Danger) 차단”

심각한 내용에 대한 실시간 AI의
팝업 알림 및 게시 차단




“사용자 결정권 강조”

최종 결정은 항상 사용자에게 있음을
명확히 함


판단은 AI가 결정은 사용자가

E-Nudge: 사용자 UI 구현 결과



Offensive (주의) 팝업

경고 팝업 노출 및 수정 제안 + shake 애니메이션
게시 강행 시 ignored_warning = 1 기록 + 관리자 배너 표시




Hate (위험) 팝업

경고 팝업 노출 및 게시 차단 + shake 애니메이션
클라이언트 원천 차단

텍스트와 이미지 동시 게시

각각의 등급 판단 후 더 높은 등급에 따라서 넋지 팝업 동작 이후 팝업 내용은 동일합니다.

※ 텍스트와 이미지가 동시 게시 된 화면




E-Nudge: 사용자 UI 구현 결과

관리자 대시보드

체계적 리스크 통합 관리망 :
댓글 추적 사후 모니터링을 지원하는 시스템

- 필터링 내역 정렬
- Ignored Warning User 리스트
- 모니터링 화면



향후 제안 (Future Works)

Phase 1 (현재)

정확도 고도화
신뢰 기반 구축

Phase 2 (6개월)

디지털 시민성
플랫폼으로 확장

Phase 3 (1년)

사회 인프라 수준의
시스템

E-Nudge 바로 접속




E-Nudge

<http://gds-fastapi-app-f2ahc6bzg6eyfach.koreacentral-01.azurewebsites.net>

07 . 책임있는 AI


“한국 특유의 시각적 조롱, 유해 이미지를 학습시키려면?”

이미지 데이터 수집 과정



악플의 이미지 진화

한국 커뮤니티에서 유통되는 시각적 혐오 이미지
(정치인 합성 짤, 비하 목적의 조롱 이모티콘, 커뮤니티 특유의 폭력적 이모티콘)



데이터의 부재

기존 혐오 데이터셋의 99%가 텍스트(NLP)에 편중되어 있으며,
한국 특유의 맥락이 담긴 이미지 기반 비전 데이터셋은
국내외를 막론하고 사실상 전무한 상황

K-Hate Vision 27,758장: 수집 방법론

```
# 1) 검색 결과 HTML에서 package_idx 추출
soup = BeautifulSoup(resp.text, "html.parser")
pkg_ids = list(dict.fromkeys(
    el["package_idx"]
    for el in soup.find_all("li", attrs={"package_idx": True})
))
```

1. 검색 기반 크롤링 실패

- Google Search API 기반 이미지 수집 시도
- 뉴스 썸네일, 캡처 이미지 등 노이즈 다수
- 실제 커뮤니티 밈과 짤 수집에는 한계


2. 커뮤니티 직접 수집

- 실제 밈이 생성·유통되는 커뮤니티 직접 분석
- HTML 파싱으로 package_idx와 이미지 경로 추적
- src, data-src 기반 실제 이미지 선별 수집

범용성과 한국 특화 혐오 데이터를 결합하여 총 27,758장의 데이터셋을 구축함


“AI가 해결할 수 없는 부분과 윤리적 보완의 필요성”

학습과정에서의 한계



타겟 데이터 선정


팬·아티스트 커뮤니티 보호 목적으로
문맥에 맞지 않게 유입되는 정치 합성 짤과
조롱 이미지를 직접 수집



맥락의 모호성

그러나 한국 커뮤니티에서 사용되는 '밈과
짤'의 경우 그 맥락에 따라 조롱의 의도 등
유해성이 결정됨

AI에게 공통된 라벨을 학습시키기 어렵다는
한계에 직면하게 됨



윤리적 보완

이러한 맥락의 모호성을 해결하기 위해
윤리 원칙적 보완이 더욱 필요해짐

맥락적 모호성을 인정하고, 윤리 원칙 적용을 통해 시스템을 보완하고자 함

"기능으로 구현하는 윤리 원칙"

인공지능 6대 원칙 × E-Nudge

투명성 :

TF-IDF 계수 기반 판정 근거 추출
관리자에게 **Toxicity Score** 수치 제공,
Transparency Note 작성

TRANSPARENCY NOTE

E-Nudge

AI 기반 댓글 유해성 분석과 사용자 재고 기회를 결합한 네티형 콘텐츠 모더레이션 시스템 설명 문서

최종 수정일: 2026-03-06

팀원: 임경아, 조윤재, 성유리, 오준상, 박용주, 황주희

MS AI School 9기 프로젝트

이 문서는 Microsoft Transparency Note 공식 구조를 따릅니다. 참고: [Azure AI Content Safety Transparency Note](#)

1. E-Nudge란 무엇인가?

E-Nudge(Empathetic Nudge)는 온라인 커뮤니티의 댓글을 AI로 분석하여 유해성을 판정하고, 사용자에게 게시 전 재고 기회를 제공하는 네티 기반 콘텐츠 모더레이션 시스템입니다.

사용자가 댓글을 작성하고 게시 버튼을 누르면, AI가 해당 텍스트를 분석하여 유해성 수준을 판정합니다. 판정 결과에 따라 네티 팝업이 표시되며, 최종 게시 결정은 항상 사용자에게 있습니다. E-Nudge는 댓글을 삭제하거나 차단하지 않습니다.

- 텍스트 분석: kiwipiepy 형태소 분석 → TF-IDF + Bigram 벡터화 → ComplementNB 분류 모델
- 3클래스 분류: none (정상) / offensive (공격적) / hate (혐오)
- 3단계 네티: Safe (즉시 게시) / Warning (이모지 네티 팝업) / Danger (경고 + 관리자 알림)
- 이미지 분석 (보조): Azure Custom Vision 기반 K-Hate Vision 데이터셋 (27,758장)

2. 의도된 용도

용도	설명
댓글 사전 검토 보조	사용자가 게시 전에 자신의 표현을 한 번 더 돌아볼 기회를 제공합니다. 행동경제학의 자유주의적 개입주의(Libertarian Paternalism)에 기반합니다.
커뮤니티 관리 모니터링	관리자가 대시보드를 통해 유해 댓글 추이, 네티 효과(수정 비율), 상위 키워드 등을 모니터링합니다.

3. 지원되지 않는 용도

- 법적 판단의 근거로 사용 - AI 판정 결과는 법적 효력이 없습니다.
- 댓글 자동 삭제 또는 게시 차단 - E-Nudge는 재고 기회를 제공할 뿐, 게시를 막지 않습니다.
- 개인 신원 식별 또는 프로파일링 - 사용자의 신원을 추적하거나 프로파일링하지 않습니다.
- 단독으로 사용자 제재(ban) 결정 - 52%의 정확도로 자동 제재 시 절반 가까온 오판이 발생할 수 있습니다.
- 검열 도구로 활용 - 네티는 선택지를 제거하지 않으며, 사용자의 최종 판단을 존중합니다.

Responsible AI Impact Assessment: E-Nudge

이 문서는 **Microsoft Responsible AI Impact Assessment Template (v2, 2022)** 의 구조를 따릅니다.
원본: [MS RAI Impact Assessment Template \(PDF\)](#).

Section 1 — 시스템 정보

1.1 시스템 프로필

항목	내용
시스템명	E-Nudge
팀명	MS AI School 9기 Team 4
최종 수정일	2026-03-06

1.2 시스템 생명주기 단계

날짜	단계
2026-02	기획 및 분석 (Planning & Analysis)
2026-02 ~ 03	설계 및 개발 (Design & Development)
2026-03-09	테스트 (Testing)
2026-03-10	구현 및 배포 / 발표 (Implementation & Deployment)
추후	유지보수 (Maintenance) — 학습 프로젝트로 종료 예정

1.3 시스템 설명

E-Nudge는 온라인 커뮤니티의 댓글을 AI로 분석하여 유해성을 판정하고, 사용자에게 게시 전 재고 기회를 제공하는 **네티 (Nudge) 기반 콘텐츠 모더레이션 시스템**입니다.

댓글 텍스트를 kiwipiepy 형태소 분석 → TF-IDF + Bigram 벡터화 → 분류 모델 (.pk1)로 처리하여 none / offensive / hate 3클래스로 판정합니다. 판정 결과에 따라 safe / warning / danger 3단계 네티 팝업을 표시하며, 최종 게시 결정은 사용자에게 있습니다.

"기능으로 구현하는 윤리 원칙"

인공지능 6대 원칙 × E-Nudge

4. 시스템의 기술적 한계

4.1 모델 성능

지표	수치	맥락
전체 정확도	약 52% (3클래스)	BEEP! 논문 BERT F1 0.525와 유사한 수준
Offensive Recall	0.56	네티지 서비스 특성상 recall 우선 설계
Hate Recall	0.50	혐오 표현의 절반을 탐지
BEEP! IAA	0.496	인간 annotator 간 일치도도 약 50% 수준으로, 사람도 절반만 동의하는 태스크

4.2 탐지 불가능한 표현

- 풍자·반어: "정말 대단하시네요"처럼 문맥상 비꼬는 표현
- 은어·신조어: 커뮤니티에서 빠르게 변형되는 유행 표현
- 암시적 혐오: 직접적인 혐오 단어 없이 맥락으로 전달되는 차별
- 초성 축약어 변형: "ㅅㅂ", "ㄸㅈ" 등의 자소 분리 표현
- offensive↔hate 경계: 공격적 표현과 혐오 표현의 구분이 가장 약함

4.3 언어 및 범위 제한

- 한국어 전용 - 다른 언어는 지원하지 않습니다.
- BEEP! 데이터 기반 - 네이버 연예 뉴스 댓글(2020년 수집)에 기반하므로, 다른 도메인이나 시기의 댓글에서는 성능이 달라질 수 있습니다.

5. 성능에 영향을 주는 요인

요인	영향
댓글의 길이	매우 짧은 댓글(1~2 단어)은 TF-IDF 벡터가 희소하여 판정 정확도가 떨어질 수 있습니다.
도메인 차이	연예 뉴스 댓글이 아닌 게임, 스포츠, 정치 등 다른 도메인에서는 성능이 달라질 수 있습니다.
시간 경과	언어 트렌드가 변화하면 모델이 학습하지 못한 새로운 표현이 등장합니다 (Data Drift).
이모지·특수문자	이모지만으로 구성된 댓글이나 특수문자 조합은 전처리 과정에서 제거될 수 있습니다.

Goal T1: 의사결정을 위한 시스템 이해 가능성 (System Intelligibility)

질문	답변
시스템 출력을 사용하여 결정을 내리는 사람은?	댓글 작성자 (네티지를 보고 수정/제시 결정)
결정의 대상은?	댓글 작성자 자신 (자신의 댓글에 대한 결정)

Goal T2: 이해관계자와의 소통 (Communication to Stakeholders)

질문	답변
시스템 도입 여부를 결정하는 사람은?	커뮤니티 운영자/서비스 관리자
이 시스템과 통합되는 시스템을 개발/배포하는 사람은?	프론트엔드 개발자 (유리), 백엔드 개발자 (용주)

Goal T3: AI 상호작용 고지 (Disclosure of AI Interaction)

질문	답변
시스템을 사용하거나 노출되는 사람은?	커뮤니티의 모든 댓글 작성자
AI 사용 고지 방법	네티지 팝업에 "AI 판정 결과입니다" 문구 표시. 서비스 첫 접속 시 AI 분석 동의 모달

2.4 공정성 고려사항

Goal F1: 서비스 품질 (Quality of Service)

영향 받는 이해관계자	우선 고려 대상 인구집단	영향 설명
댓글 작성자	사투리/방언 사용자, 은어/신조어 사용자	TF-IDF는 표준어 기반 BEEP! 데이터로 학습되어, 사투리나 비표준 표현을 과도하게 유해로 판정할 수 있음
댓글 작성자	특정 주제 토론 참여자 (정치, 젠더 등)	특정 주제에서 자주 등장하는 단어가 TF-IDF 가중치 편향으로 인해 과잉 탐지될 가능성

Goal F2: 자원 및 기회 배분 (Allocation of Resources and Opportunities)

해당 없음. E-Nudge는 자원이나 기회를 배분하는 시스템이 아닙니다.

Goal F3: 고정관념·비하·소거 최소화 (Minimization of Stereotyping)

책임성 :

AI 판정과 사용자 행동 전부 기록
오탐 신고를 재학습 데이터로 환류

최종 삭제 권한은 관리자 보유

RAI Impact Assessment로
위험과 대응 문서화

"기능으로 구현하는 윤리 원칙"

인공지능 6대 원칙 × E-Nudge

공정성 :

BEEP! 인간 레이블링 기반 데이터 활용
텍스트(NLP)와 이미지(CV) 결과 교차 검증
신고 데이터 반영을 통한 편향 수정

Korean HateSpeech Dataset

We provide the first human-annotated Korean corpus for toxic speech detection and the large unlabeled corpus. The data is comments from the Korean entertainment news aggregation platform.


Dataset description

The dataset consists of 3 parts: 1) `labeled` 2) `unlabeled` and 3) `news_title` .

1. `labeled`

There are **9,381** human-labeled comments in total. They are splitted into 7,896 training set, 471 validation set, and 974 test set. (We left test set labels undisclosed for the fair comparison of prediction models. The model can be evaluated via the Kaggle submission which will be described later in this document.) Each comment is annotated on two aspects, the existence of **social bias** and **hate speech**, given that hate speech is closely related to bias.

For social bias, we present `gender` , `others` , and `none` bias labels. Considering the context of Korean entertainment news where public figures encounter stereotypes mostly intertwined with *gender*, we weigh more on the prevalent bias. We also added binary label `whether a comment contains gender bias or not` . For hate speech, we introduce `hate` , `offensive` , and `none` labels.



"기능으로 구현하는 윤리 원칙"

인공지능 6대 원칙 × E-Nudge

⚠ 잠시만요! 작성하신 내용에 상대방이 불쾌감을 느낄 수 있는 표현이 포함되어 있습니다.

※ 경고를 확인했지만 게시하면 관리자에게 기록됩니다.

AI 판정 결과입니다. 기술적 한계로 인해 오류가 있을 수 있습니다.

확인

수정

신뢰성 :

3단계 점진적 개입 none, offensive, hate
3단계 점진적 개입

“AI 판정 결과입니다” 한계 고지
텍스트·이미지 이중 판정
사용자 신고 및 관리자 검토로 오탐·미탐 보완

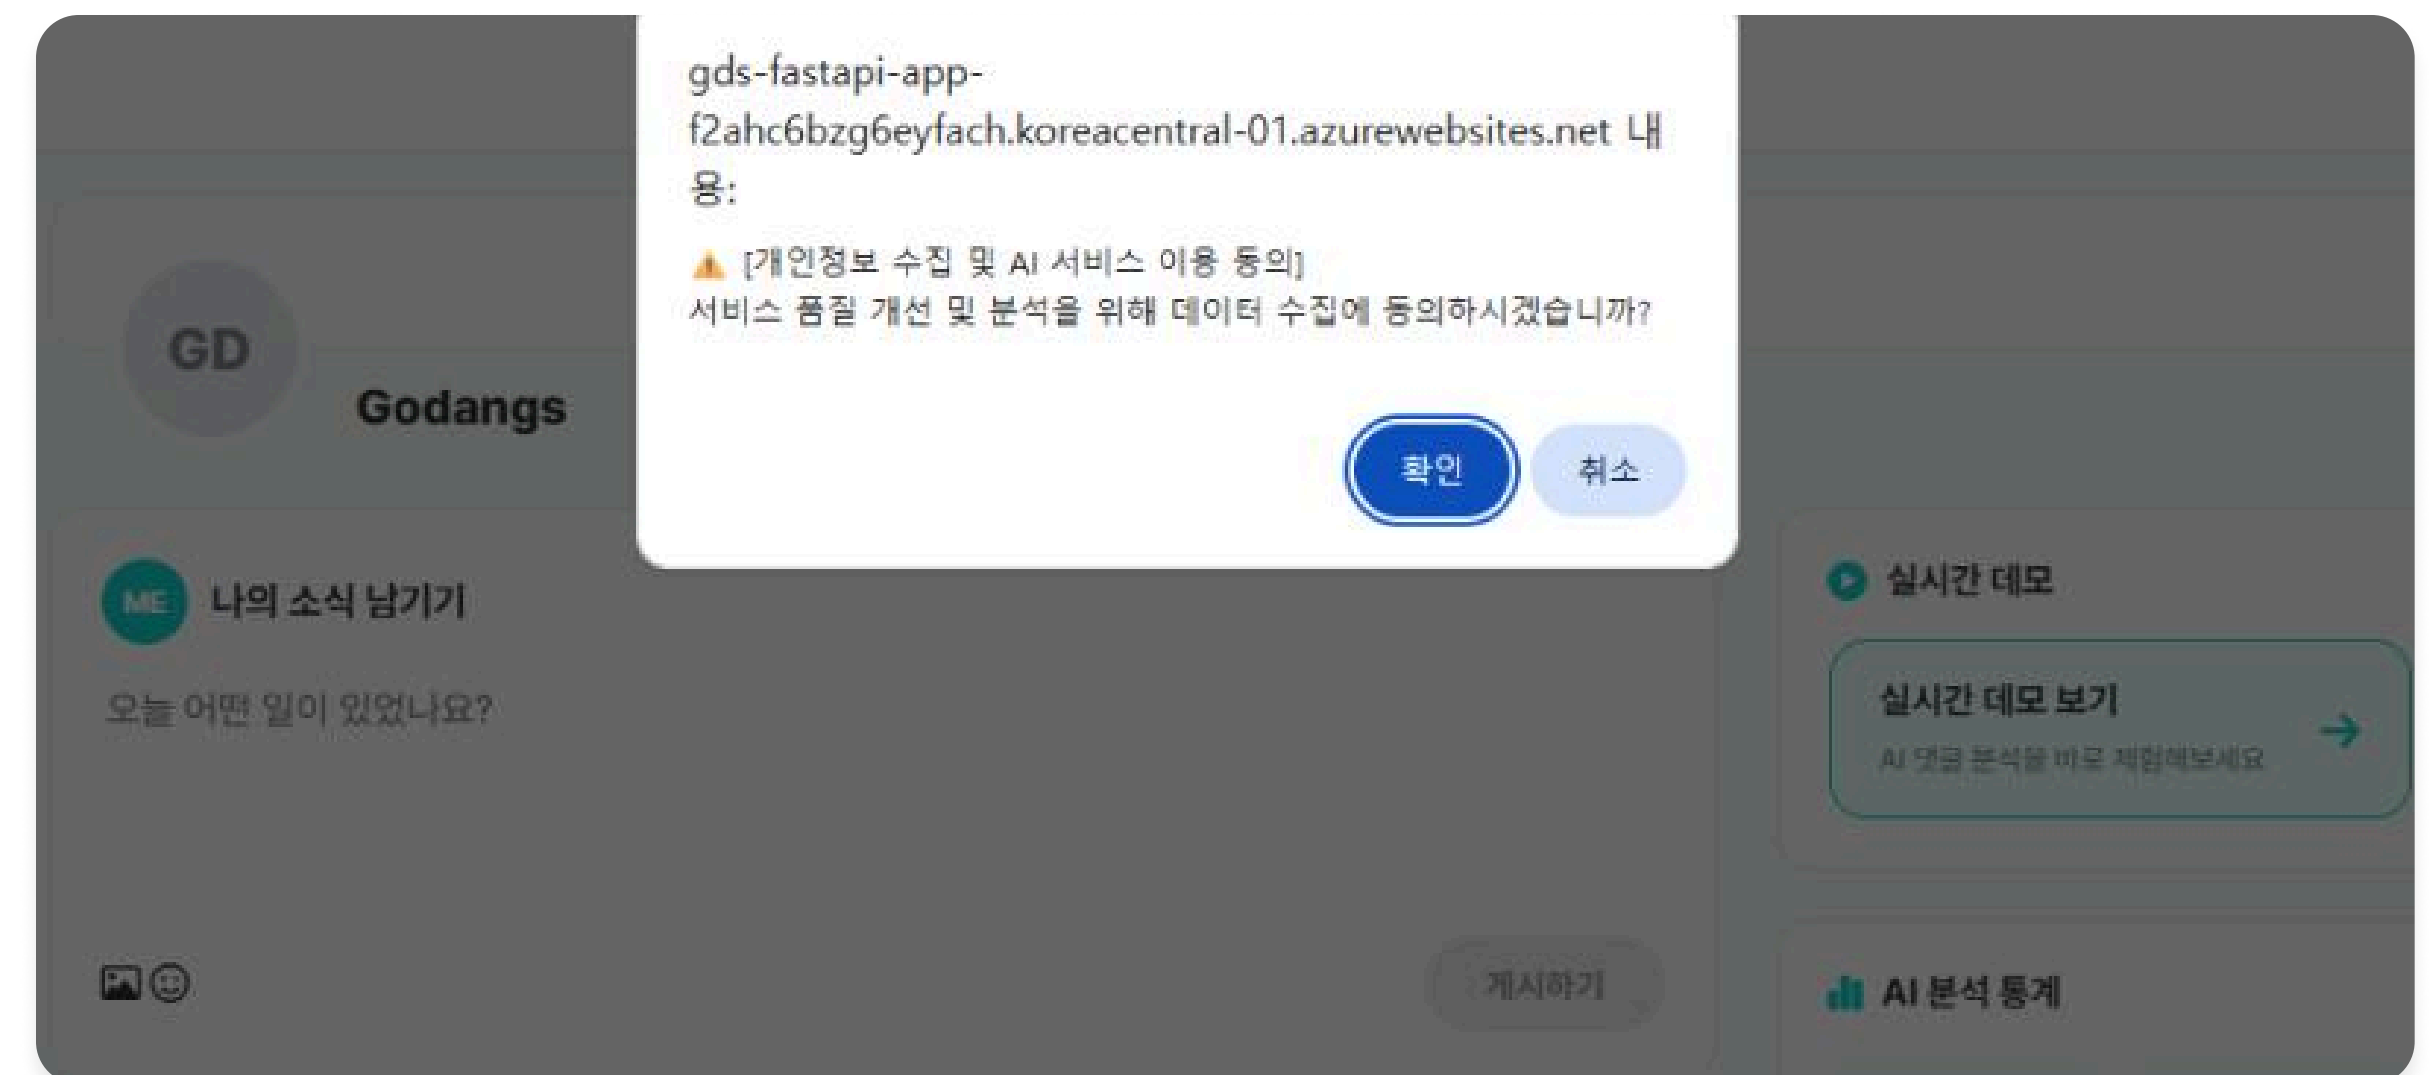
"기능으로 구현하는 윤리 원칙"

인공지능 6대 원칙 × E-Nudge

개인정보·보안 :

toxicity_score 중심 저장, 원문 최소 보존
첫 접속 시 개인정보 수집 및 AI 서비스 이용 동의 팝업 제공

이미지 원본은 Azure Blob Storage 보안 URL로 관리
댓글 데이터와 관리 로그 분리



"기능으로 구현하는 윤리 원칙"

인공지능 6대 원칙 × E-Nudge



포용성 :

장애인 비하, 성차별 이미지 등 사회적 약자 대상 혐오를 고려
넛지의 방식으로 사회적 낙인과 역차별 문제 우려 완화

색상·아이콘·텍스트 병행으로 더 다양한 사용자 접근성 보완
글로벌 확장 시 더 풍부한 데이터셋으로 발전 가능한 구조 고려가능



결론

E-Nudge가 주목하는 것



NUDGE